PLANEJAMENTO CONSOLIDADO
Tech Challenge - Fase 4

Voice of Customer Intelligence com RAG | Versão 1.0 | 08/11/2026
Documento de referência para implementação e futuras consultas.

1. Objetivo e escopo

Desenvolver uma aplicação de perguntas e respostas sobre avaliações textuais de clientes do Brazilian E-Commerce Public Dataset by Olist. A solução deve recuperar comentários relevantes, gerar respostas com um modelo de linguagem e apresentar evidências rastreáveis. A entrega seguirá o princípio 80/20: cumprir integralmente os requisitos com a menor complexidade justificável.

2. Requisitos obrigatórios do enunciado

Requisito	Implementação prevista
Base de conhecimento	Selecionar e limpar avaliações, tratar ausentes, organizar documentos, gerar embeddings e indexar.
Pipeline RAG	Transformar a pergunta, recuperar semanticamente, selecionar evidências, montar contexto e gerar resposta.
Fundamentação	Exibir avaliações e identificadores que sustentam os insights, sem extrapolar as evidências.
Insuficiência de evidências	Reconhecer consultas sem resultados relevantes, evidências insuficientes e perguntas fora do escopo.

3. Tecnologias propostas (a validar na execução)

Python (linguagem); Streamlit (interface); LangChain (orquestração); Sentence Transformers com modelo multilíngue (embeddings); ChromaDB (armazenamento vetorial); LLM via API (provedor/modelo ainda não definido); GitHub (repositório público). Execução inicial local. Sem LangGraph, agentes, fine-tuning ou nuvem na versão inicial.

4. Fluxo funcional definido

Preparação (offline): CSV Olist → seleção/limpeza → documentos identificáveis → embeddings → índice ChromaDB.

Consulta (online): pergunta → normalização/preparação explícita → embedding → busca vetorial → filtragem por similaridade e deduplicação → verificação de suficiência → contexto com evidências → LLM → resposta com fontes. Se a validação falhar, responder que não há evidências suficientes.

5. Regras iniciais de recuperação e resposta

Parâmetro	Decisão de planejamento
Top-k	Comparar k = 10, 20 e 30; escolha final após testes.
Similaridade	Cosseno; limiar mínimo será calibrado com resultados reais, não fixado arbitrariamente.
Deduplicação	Eliminar duplicidade por ID de avaliação e texto quando aplicável.
Mínimo de evidências	Hipótese inicial: 3 avaliações relevantes para sínteses; não garante representatividade.
Re-ranking	Não implementar no MVP, salvo evidência de necessidade.
Sem evidência	Combinar limiar, quantidade mínima pertinente e instrução explícita no prompt para não inventar.

6. Limitação metodológica deliberada

A busca semântica identifica comentários relacionados à pergunta, não mede a frequência dos temas em toda a base. Para perguntas como “quais reclamações aparecem com maior frequência?”, a versão inicial usará linguagem restrita: “nas avaliações recuperadas, aparecem...”. Não afirmará rankings ou frequências populacionais sem contagem adequada. Registrar essa limitação no README.

7. Avaliação e critérios de qualidade

Construir 12 perguntas de teste abrangendo reclamações, entrega, elogios, qualidade, insatisfação e fora do escopo. Comparar top-k de 10, 20 e 30 mantendo fixos base, embeddings, perguntas e critérios de julgamento. Registrar relevância manual dos resultados, Precision@k, cobertura temática qualitativa, tempo de recuperação, suporte das respostas nas evidências e recusa correta/incorreta para perguntas fora do escopo (ex.: “Qual o melhor smartphone de 2025?”).

8. Decisões e justificativas técnicas

Manter docs/decisoes_tecnicas.md atualizado durante a execução, com: decisão, justificativa, alternativa descartada e evidência de validação. Registrar obrigatoriamente seleção, limpeza, ausentes, organização dos documentos, embeddings, indexação, recuperação e geração.

9. Etapas de execução

Etapa	Resultado esperado
1. Análise exploratória	Inspecionar o arquivo olist_order_reviews_dataset.csv: volume, textos disponíveis, ausentes, notas, duplicidades e comprimento.
2. Preparação/indexação	Base tratada, embeddings gerados e ChromaDB populado.
3. Pipeline RAG	Consulta transformada, recuperação, filtros, evidências e respostas com recusa quando necessário.
4. Interface/testes	Aplicação Streamlit e avaliação comparativa documentada.
5. Entrega	Repositório público com README reproduzível e vídeo de até 7 minutos.

10. Entregáveis e observações do enunciado

GitHub público: código, instalação/execução, README, arquitetura, bibliotecas, pipeline, preparação dos dados, justificativas, exemplos de perguntas/respostas e reprodução. Vídeo: até 7 minutos, incluindo problema, arquitetura, recuperação, demonstração, evidências e decisões técnicas. Opcional: enriquecer com metadados; nota da avaliação é a primeira melhoria recomendada, se viável. O enunciado também menciona trilha Databricks com possibilidade de 10 pontos extras mediante comprovação; não integra o MVP.

11. Próxima ação e estado atual

Estado: planejamento consolidado; implementação e resultados ainda não iniciados. Próxima ação: obter olist_order_reviews_dataset.csv e executar análise exploratória, sem assumir antecipadamente quantidade de avaliações textuais ou qualidade dos dados. Só então confirmar tratamentos e iniciar indexação.

Fonte principal

FIAP/POSTECH. [IAST] - Tech Challenge - Fase 4, páginas 2 a 10 (enunciado fornecido). Este documento separa exigências do enunciado de escolhas técnicas propostas no planejamento.